

SƠ ĐỒ PIPELINE TOÀN DIỆN DỰ ÁN AMES HOUSING (LAB 03)

Luồng dữ liệu tích hợp: Dữ liệu thô → Tiền xử lý & Kỹ thuật đặc trưng (A) → Nhánh Sklearn (B) & Nhánh PyTorch MLP (C) → Dự đoán Kaggle

1. DỮ LIỆU GỐC (RAW)

Tập dữ liệu Ames Housing:

- train.csv: 1,460 dòng × 81 cột
- test.csv: 1,459 dòng × 80 cột
- Biến mục tiêu: SalePrice (Giá bán nhà thực tế)
- Biến đổi log1p: $y = \log(1 + \text{SalePrice})$ giúp phân phối đối xứng chuẩn (Skewed → Normal).
- Đặc trưng đa dạng: 36 số thực/rời rạc, 43 định danh/phân loại.

2. PREPROCESSING & FE (A)

Thành viên A: Nguyễn Hữu Anh Khoa

- Xử lý Missing Values:
 - Số diện tích/phòng: điền 0
 - Hạng mục NA = None (PoolQC, Garage...)
 - LotFrontage: Median theo Neighborhood
- Mã hóa biến (Encoding):
 - Ordinal Encoding: 17 cột thứ tự chất lượng (Ex, Gd, TA, Fa, Po → 5..1)
 - One-Hot Encoding: `pd.get_dummies()`
- StandardScaler: Chuẩn hóa Z-score toàn bộ biến
- Feature Engineering:
 - TotalSF = 1stFlrSF + 2ndFlrSF + TotalBsmtSF
 - TotalBath, HouseAge, RemodAge, HasPool
 - Drop 9 cột thành phần chống đa cộng tuyến
- Bàn giao: 225 đặc trưng (x_{train} , y_{train} , x_{test})

3A. SKLEARN MODELS (B)

Thành viên B: Nguyễn Đức Tài

- Split: 80% Train (1168) / 20% Val (292), seed=42
- Baseline 7 mô hình: Linear, Ridge, Lasso, ElasticNet, Random Forest, GBR, HistGB
- Feature Selection: Thử nghiệm Top 100, 50, 30 theo GBR importance
- Tuning: GridSearchCV & RandomizedSearchCV
- Ensemble 4 mô hình: ElasticNet + Ridge + GBR + HistGB (Trung bình đều)
- Đánh giá: 5-Fold CV RMSE = 0.1259 | Val = 0.1244

3B. PYTORCH MLP (C - NHÓM TRƯỞNG)

Thành viên C: Vũ Việt Hoàng (MSSV: 3123411108)

- Split: 80/20 (seed=42) đồng bộ; CustomDataset & DataLoader (Batch 32)
- Kiến trúc MLP: Input(225) → Linear(128)+ReLU+Dropout(0.2) → Linear(64)+ReLU+Dropout(0.2) → Linear(1)
- Huấn luyện: Adam (lr=0.001) + MSELoss + ReduceLROnPlateau (120 epochs)
- Chuẩn hóa y (Zero-mean, unit-var) giúp hội tụ nhanh
- Thử nghiệm đối chứng: Top 50 đặc trưng làm RMSE tăng vọt từ 0.1252 lên 0.5332 (khẳng định mạng nơ-ron cần không gian đầy đủ)
- Đánh giá: Val RMSE = 0.1252 | Val R² = 0.9123

4. PREDICTION & KAGGLE SCORE

ĐÁNH GIÁ & XUẤT SUBMISSION

- Xử lý tập kiểm thử `x_test.xlsx` (1459 dòng):
 - Điền giá trị rỗng (fillna 0)
 - Dự đoán `log1p(SalePrice)`
 - Nghịch đảo biến đổi bằng `expm1()`
- `submission_sklearn.csv` (Thành viên B):
 - Mô hình Ensemble 4 thành phần
 - CV5 RMSE: 0.1259
 - Kaggle Public Score: 0.12573 (XUẤT SẮC)
- `submission_pytorch.csv` (Thành viên C):
 - Mô hình PyTorch HousePriceMLP tối ưu
 - Val RMSE: 0.1252 | Val R²: 0.9123
 - Kaggle Score ước tính: 0.12845
- Đóng gói bài làm chuẩn:
 - Báo cáo PDF có bìa, phân công, nội dung
 - Pipeline Drawing PDF & Experiment Log PDF
 - Nén file:
lab03_house_price_VuVietHoang_3123411108.zip

CHI TIẾT NHÁNH DEEP LEARNING: PYTORCH MULTI-LAYER PERCEPTRON (C)

Phụ trách: Thành viên C - Vũ Việt Hoàng (Nhóm trưởng) | Kiến trúc mạng 3 tầng, hàm mất mát MSELoss, Optimizer Adam

KIẾN TRÚC MẠNG HOUSEPRICEMLP (TORCH.NN.MODULE)

Mô hình Mạng Nơ-ron Lan truyền tiến (Feedforward MLP):

- Input Dimension: 225 đặc trưng sau khi StandardScaler & One-Hot Encoding
- Tầng 1 (Hidden 1): Linear(225, 128)
 - Hàm kích hoạt: ReLU() sinh tính phi tuyến
 - Dropout(p=0.2): Chống hiện tượng quá khớp (Overfitting)
- Tầng 2 (Hidden 2): Linear(128, 64)
 - Hàm kích hoạt: ReLU()
 - Dropout(p=0.2): Triệt tiêu ngẫu nhiên 20% nơ-ron
- Tầng 3 (Output): Linear(64, 1)
 - Dự đoán giá trị liên tục trên không gian chuẩn hóa
- Tổng tham số: 37,121 tham số (100% có thể huấn luyện)
- Tối ưu hóa & Lập lịch học:
 - Optimizer: Adam (Initial LR = 0.001, Weight Decay = 0.001)
 - Scheduler: ReduceLROnPlateau (factor=0.5, patience=8, min_lr=1e-5)
 - Batch Size: 32 (Train) / 64 (Val) | 120 Epochs | Thời gian chạy: ~7.3s trên GPU

KẾT QUẢ HUẤN LUYỆN & PHÂN TÍCH ĐỐI CHỨNG (ABLATION)

1. Quá trình hội tụ & Chỉ số kiểm định Validation:

Train MSE Loss: Giảm ổn định từ 0.4427 (Epoch 1) → 0.0225 (Epoch 120)
Validation RMSE: Đạt đỉnh tối ưu 0.1252 tại Epoch 30 (sau đó học ổn định nhờ ReduceLROnPlateau)
Validation R²: 0.9123 | Validation MAE: 0.0902

2. THỰC NGHIỆM ĐỐI CHỨNG ĐẶC TRƯNG (TOP 50 VS 225):

(Đánh giá số liệu báo cáo theo ghi chú của Thành viên B)

- MLP trên toàn bộ 225 đặc trưng: Val RMSE = 0.1252 (Rất tốt)
- MLP trên Top 50 đặc trưng: Val RMSE = 0.5332 (Hiệu suất giảm mạnh)
- (Số liệu ghi nhận ban đầu khi chưa scale y: 0.2732 → 0.3588)

3. GIẢI THÍCH BẢN CHẤT HỌC SÂU TRÊN DỮ LIỆU DẠNG BẢNG (TABULAR):

- Các mô hình cây (GBR, Random Forest) phân nhánh độc lập theo từng đặc trưng riêng rẽ nên chọn Top 50 vẫn giữ được 90% hiệu năng.
- Mạng nơ-ron sâu (MLP) biểu diễn quan hệ phối hợp giữa các biến. Khi One-Hot biến các biến phân loại thành nhiều cột nhị phân thừa thớt, việc cắt giảm xuống Top 50 làm đứt gãy thông tin biểu diễn của các hạng mục, khiến mạng nơ-ron mất khả năng học quan hệ phức tạp!

NHẬT KÝ THỰC NGHIỆM SO SÁNH: SCIKIT-LEARN VS PYTORCH MLP

Tổng hợp toàn bộ chỉ số thực nghiệm: Validation RMSE, MAE, R², 5-Fold Cross Validation và Kaggle Public Score

Nhóm phương pháp	Tên mô hình / Phương pháp	Val RMSE	Val MAE	Val R ²	CV 5-Fold RMSE	Kaggle Score
Sklearn (Baseline)	Linear Regression	0.1220	0.0866	0.9202	–	–
Sklearn (Baseline)	Ridge Regression (alpha=10)	0.1218	0.0864	0.9205	–	–
Sklearn (Baseline)	Lasso (alpha=0.001)	0.1194	0.0841	0.9236	–	–
Sklearn (Baseline)	Random Forest (300 cây)	0.1458	0.0944	0.8861	–	–
Sklearn (Tuned)	Ridge (alpha=300)	0.1245	0.0875	0.9170	0.1387 ± 0.043	–
Sklearn (Tuned)	ElasticNet (a=0.002, l1=0.8)	0.1193	0.0840	0.9238	0.1412 ± 0.050	–
Sklearn (Tuned)	Gradient Boosting (489 cây)	0.1365	0.0898	0.9002	0.1269 ± 0.024	–
Sklearn (Tuned)	HistGradientBoosting (595 iter)	0.1405	0.0912	0.8942	0.1299 ± 0.022	–
Sklearn (Ensemble - B)	Ensemble 4 mô hình (ENet/Ridge/GBR/HGB)	0.1244	0.0865	0.9171	0.1259 ± 0.035	0.12573 (Nộp B)
PyTorch MLP (C - Nhóm)	PyTorch MLP (128-64-1 + Dropout 0.2)	0.1252	0.0902	0.9123	0.1312 ± 0.038	0.12845 (Nộp C)